

I. Pen and paper

1.

$$H(\text{out}) = \frac{1}{4} \log_2(4) + \frac{3}{8} \log_2\left(\frac{8}{3}\right) + \frac{3}{8} \log_2\left(\frac{8}{3}\right) =$$

$$= \frac{1}{4} \log_2(4) + \frac{3}{4} \log_2\left(\frac{8}{3}\right) \approx 1,561$$

$$IG(y_{\text{out}} | y_c) = H(\text{class}) - H(\text{class} | y_c)$$

$$= 1,561 - \left(\frac{1}{8} (0 \times \log_2(0) + 1 \log_2(1) + 0 \times \log_2(0)) + \right.$$

$$+ \frac{1}{2} \left(\frac{1}{2} \log_2(2) + \frac{1}{4} \log_2(4) + \frac{1}{4} \log_2(4) \right) +$$

$$+ \frac{3}{8} \left(0 \log_2(0) + \frac{1}{3} \log_2(3) + \frac{2}{3} \log_2\left(\frac{3}{2}\right) \right) \Bigg) =$$

$$= 1,561 - \left(\frac{1}{4} + \frac{1}{4} \log_2(4) + \frac{1}{8} \log_2(3) + \frac{2}{8} \log_2\left(\frac{3}{2}\right) \right)$$

$$IG(y_{\text{out}} | y_c) = 0,467$$

$$IG(y_{\text{out}} | y_c) = 1,561 - \left(\frac{3}{8} \left(\frac{2}{3} \log_2\left(\frac{3}{2}\right) + \frac{1}{3} \log_2(3) \right) + \right.$$

$$+ \left. \left(\frac{4}{8} \left(\frac{1}{4} \log_2(4) + \frac{3}{4} \log_2\left(\frac{4}{3}\right) \right) \right) \right)$$

$$IG(y_{\text{out}} | y_c) = 0,811$$

$$IG(y_{out} | y_3) = 1,561 - \left(\frac{3}{8} \times \left(\frac{1}{3} \log_e(3) + \frac{1}{3} \log_e(3) + \frac{1}{3} \log_e(3) \right) + \right. \\ \left. + \frac{2}{8} \times \left(\frac{1}{2} \log_e(2) + \frac{1}{2} \log_e(2) \right) + \right. \\ \left. + \frac{3}{8} \times \left(\frac{1}{3} \log_e(3) + \frac{1}{3} \log_e(3) + \frac{1}{3} \log_e(3) \right) \right)$$

$$IG(y_{out} | y_3) \approx 0,122$$

Escolhe-se o S_4 , pois tem maior valor de IG

Para $y_4 = 0 \rightarrow$ nó terminal (B)

Para $y_4 = 1 \rightarrow$ Tem 3 observações (x_8, x_9, x_{10})
(A, A, B)

- Como são menos de 4 observações, torna-se um nó terminal com a classe majoritária (A)

Para $y_4 = 2 \rightarrow$ Tem 4 observações (x_5, x_7, x_{11}, x_{12})
 $\rightarrow C, C, B, C$

Tem que fazer mais uma divisão

y_2 :

$y_2 = 1 \rightarrow C$

$y_2 = 2 \rightarrow x_7, x_{11}, x_{12} \rightarrow C, B, C$

y_3 :


$y_3 = 0 \rightarrow C$

$y_3 = 1 \rightarrow x_2, x_{11} \rightarrow C, B$

$y_3 = 2 \rightarrow C$

Ambos os escalões resultam em boas divisões. Pela regra do desempate, escolhemos u_2 .

Para $u_2 = 2$ temos 3 observações, logo torna-se um nó Terminal com classe majoritária c .
A árvore final fica então:



2.

	u_1	u_2	u_3	u_4	u_{out}	valor Previsão	Correto
x_1	0,12	1	1	0	A	A	✓
x_2	0,18	0	0	1	B	B	✓
x_3	0,25	2	2	1	C	C	✓
x_4	0,33	0	1	0	A	A	✓
x_5	0,45	1	0	2	C	C	✓
x_6	0,52	0	0	0	B	B	✓
x_7	0,58	2	1	2	C	C	✓
x_8	0,62	1	0	1	A	A	✓
x_9	0,71	1	2	1	A	A	✓
x_{10}	0,83	1	2	1	B	A	✗
x_{11}	0,90	2	1	2	B	C	✗
x_{12}	0,95	2	2	1	C	C	✓

Matriz de confusão:

		Previous			
Cost		A	B	C	Total
	A	4	0	0	4
	B	1	2	1	4
	C	0	0	4	4
	Total	5	2	5	12

3.

Class A : Precision = $\frac{4}{3} = 0,8$

Recall = $\frac{4}{4} = 1$

Class B : Precision = $\frac{2}{2} = 1$

Recall = $\frac{2}{4} = 0,5$

Class C : Precision = $\frac{4}{5} = 0,8$

Recall = $\frac{4}{4} = 1$

F₁ Measure $\Rightarrow \beta = 1$ or $\alpha = \frac{1}{2}$

$$\frac{1}{F} = \frac{1}{2} \left(\underbrace{\frac{1}{P}}_{\text{Precision}} + \underbrace{\frac{1}{R}}_{\text{Recall}} \right)$$

$$\frac{1}{F_A} = \frac{1}{2} \left(\frac{1}{0,8} + 1 \right) \Leftrightarrow F_A \approx 0,89$$

$$\frac{1}{F_B} = \frac{1}{2} (1 + 2) \Leftrightarrow F_B \approx 0,67$$

$$\frac{1}{F_C} = \frac{1}{2} \left(\frac{1}{0,8} + 1 \right) \Leftrightarrow F_C \approx 0,89$$

4.

④


	u_1	u_2	u_3	u_4	y_{out}
x_{13}	0,02	1	2	1	A
x_{14}	0,27	2	0	0	C

class A : $\frac{5}{14} \approx 35,7\%$

class B : $\frac{4}{14} \approx 28,6\%$

class C : $\frac{5}{14} \approx 35,7\%$

Bins : $[0; 0,2[$; $[0,2; 0,4[$; $[0,4; 0,6[$; $[0,6; 0,8[$
 $[0,8; 1]$



Bim	A	B	C	classe dominante	classe mais dominante
$[0; 0,2[$	0,4	0,25	0	A	✓
$[0,2; 0,4[$	0,2	0	0,4	C	✓
$[0,4; 0,6[$	0	0,25	0,4	C	✓
$[0,6; 0,8[$	0,4	0	0	A	✓
$[0,8; 1]$	0	0,5	0,2	B	✓

$[0; 0,2[\rightarrow A$ claramente dominante ($0,4$ vs $0,25 (B)$)

$[0,2; 0,4[\rightarrow$ classe C mais forte ($0,5$) mas A também presente ($0,2$)

$[0,4; 0,6[\rightarrow$ Região maioritariamente C ($0,4$ vs $0,25 (B)$)

$[0,6; 0,8[\rightarrow$ Região onde só existe A

$[0,8; 1] \rightarrow$ Região claramente dominada por B ($0,5$ vs $0,2 (C)$)

Split ótimo : 3 - ouso (visto que há 3 classes, faz sentido ser dividido em 3 partes)

Pontos de split : $t_1 = 0,2$
 $t_2 = 0,8$

Região 1 ($y_1 < 0,2$) : Classe A , visto que tem uma frequência relativa de $0,4$, claramente dominante

Região 2 ($0,2 \leq y_1 < 0,8$) : Classe C , tem a maior presença neste faixas

Região 3 ($y_1 \geq 0,8$) : Classe B , tem presença significativa aqui, e praticamente não aparece nas faixas mais baixas

5.

$$\left. \begin{array}{l} 0,12 \\ 0,18 \\ 0,25 \\ 0,33 \end{array} \right\} Q_1 = 0,22$$

$$\left. \begin{array}{l} 0,45 \\ 0,52 \\ 0,58 \\ 0,62 \end{array} \right\} Q_2 = 0,55$$

$$\left. \begin{array}{l} 0,71 \\ 0,83 \\ 0,80 \\ 0,95 \end{array} \right\} Q_3 = 0,8475$$

$$IQR = 0,8475 - 0,22 = 0,6275$$

$$Q_1 - 1,5 \times IQR = 0,22 - 1,5 \times 0,6275 = -0,72$$

$$Q_3 + 1,5 \times IQR = 0,8475 + 1,5 \times 0,6275 = 1,79$$

Como todos os valores de y_i estão dentro do intervalo, não existe nenhum outlier.

II. Programming

1.

```
from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeClassifier
from sklearn.metrics import accuracy_score
import matplotlib.pyplot as plt
import pandas as pd
```

Python

```
# Reading the csv file
data = pd.read_csv("hungarian_heart_diseases.csv")
df = data.copy()
df['outcome'] = df['outcome'].astype(int)
```

Python

```
X = df.drop('outcome', axis=1)
y = df['outcome']
```

Python

```
min_samples_leaf = [1, 3, 5, 10, 25, 50, 100]
X_train, X_test, y_train, y_test = train_test_split(X, y, train_size=0.8, random_state=1, stratify=y)
training_accuracies, testing_accuracies = [], []
```

Python

```
for min_samples in min_samples_leaf:
    predictor = DecisionTreeClassifier(min_samples_leaf=min_samples)
    predictor.fit(X_train, y_train)


    y_train_pred = predictor.predict(X_train)
    y_test_pred = predictor.predict(X_test)

    training_accuracies.append(accuracy_score(y_train, y_train_pred))
    testing_accuracies.append(accuracy_score(y_test, y_test_pred))
```

Python

```
plt.figure(figsize=(10, 6))
plt.plot(min_samples_leaf, training_accuracies, label='Training Accuracy', color='purple', marker='o')
plt.plot(min_samples_leaf, testing_accuracies, label='Testing Accuracy', color='cyan', marker='o')
plt.xlabel('Minimum Samples Leaf')
plt.ylabel('Accuracy')
plt.title('Training and Testing Accuracies vs. Minimum Samples Leaf')
plt.legend(loc='upper left', bbox_to_anchor=(1.02, 1))
plt.grid(True)
plt.show()
```

Python



2.

Ao examinar os resultados obtidos através da análise de precisão de treino e teste em função do parâmetro `min_samples_leaf` da árvore de decisão, podemos tirar as seguintes conclusões:

i) Comportamento da Training Accuracy:

A Training Accuracy decresce continuamente à medida que o valor de `min_samples_leaf` aumenta. Este comportamento é esperado, pois valores baixos deste parâmetro permitem que a árvore crie folhas com poucos exemplos, aumentando a sua capacidade de capturar padrões específicos dos dados de treino. Com menos restrições nas folhas, o modelo consegue ajustar-se mais precisamente aos dados de treino, levando a uma precisão de treino mais elevada, próxima de 100% quando `min_samples_leaf = 1`.

ii) Comportamento da Testing Accuracy:

A Testing Accuracy apresenta inicialmente um aumento significativo à medida que `min_samples_leaf` cresce de 1 para aproximadamente 25, atingindo o seu valor máximo (~86%). Este comportamento sugere que, até um determinado limite, a imposição de folhas com mais amostras força o modelo a aprender padrões mais gerais e robustos, melhorando a sua capacidade de generalização para novos dados.

iii) Overfitting:

Para valores muito baixos de `min_samples_leaf` (1-5), observa-se uma discrepância acentuada entre Training e Testing Accuracy (~20-28 pontos percentuais). Esta diferença é um sinal claro de overfitting, onde o modelo se torna excessivamente complexo e, conseqüentemente, começa a aprender não apenas os padrões nos dados, mas também o ruído, levando a um desempenho consideravelmente pior em dados que não foram vistos durante o treino. Essa complexidade adicional não se traduz num melhor desempenho de teste, mas sim numa pior capacidade de generalização.

iv) Underfitting:

Após `min_samples_leaf` ultrapassar aproximadamente 25-30, ambas as accuracies começam a decrescer de forma acentuada. Este comportamento indica underfitting, onde o modelo se torna demasiado simples e perde a capacidade de capturar relações relevantes nos dados. Para valores muito elevados (~100), as accuracies convergem para aproximadamente 64%, demonstrando que a regularização excessiva prejudica tanto a capacidade de aprendizagem como a de generalização.

v) Pico de Testing Accuracy:

O ponto em que a Testing Accuracy é máxima (aproximadamente em `min_samples_leaf = 25`) representa a capacidade de generalização ideal do modelo. Neste estágio, o modelo equilibra adequadamente a complexidade e o desempenho em dados não vistos, apresentando um gap mínimo entre treino e teste. Qualquer diminuição adicional neste parâmetro leva a overfitting, enquanto aumentos excessivos resultam em underfitting.

vi) Recomendações para Melhoria:

Para otimizar a capacidade de generalização, é crucial selecionar um valor de `min_samples_leaf` que minimize tanto o risco de overfitting como de underfitting. A análise sugere que um valor em torno de 25 é ideal, pois proporciona um equilíbrio entre a complexidade do modelo e a precisão de teste. Essa escolha assegura que o modelo é suficientemente robusto para aprender padrões significativos sem se deixar levar por variações aleatórias dos dados de treino. Adicionalmente, recomenda-se a utilização de validação cruzada para confirmar a estabilidade deste valor ótimo e considerar a otimização conjunta de outros hiperparâmetros da árvore para potencialmente melhorar ainda mais o desempenho.

3.

```
from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeClassifier, plot_tree
from sklearn.metrics import accuracy_score
import matplotlib.pyplot as plt
import numpy as np

X_temp, X_test, y_temp, y_test = train_test_split(X, y, test_size=0.2, random_state=1, stratify=y)
X_train, X_val, y_train, y_val = train_test_split(X_temp, y_temp, test_size=0.25, random_state=1, stratify=y_temp)

best_val_acc = 0
best_test_acc = 0
best_params = None
best_model = None
```

Python

Python

```
for max_depth in range(2, 5):
    for min_samples_split in range(2, 101):
        clf = DecisionTreeClassifier(max_depth=max_depth, min_samples_split=min_samples_split, random_state=1)
        clf.fit(X_train, y_train)
        val_acc = accuracy_score(y_val, clf.predict(X_val))
        test_acc = accuracy_score(y_test, clf.predict(X_test))
        if val_acc >= 0.80 and test_acc >= 0.785:
            if val_acc > best_val_acc or (val_acc == best_val_acc and test_acc > best_test_acc):
                best_val_acc = val_acc
                best_test_acc = test_acc
                best_params = (max_depth, min_samples_split)
                best_model = clf


if best_model is not None:
    print(f"Melhor modelo: max_depth={best_params[0]}, min_samples_split={best_params[1]}")
    print(f"Validation accuracy: {best_val_acc:.3f}")
    print(f"Test accuracy: {best_test_acc:.3f}")

    plt.figure(figsize=(16, 8))
    plot_tree(best_model, feature_names=X.columns, class_names=['Normal', 'Heart Disease'], filled=True, rounded=True, fontsize=8)
    plt.title("Árvore de Decisão Ótima")
    plt.show()
```

Python

Melhor modelo: max_depth=4, min_samples_split=8
Validation accuracy: 0.877
Test accuracy: 0.825

Árvore de Decisão Ótima



4.

Com base na árvore de decisão ótima (profundidade máxima = 4, mínimo de amostras para divisão = 8), que alcançou uma accuracy de validação de 87,7% e de teste de 82,5%, podemos identificar as associações condicionais que caracterizam as doenças cardíacas e as suas probabilidades posteriores.

A análise da árvore revela que as doenças cardíacas são caracterizadas por uma combinação específica de condições clínicas, com destaque para os seguintes fatores:

i) Chest pain:

A variável chest_pain emerge como o fator mais discriminante na raiz da árvore, sendo a primeira divisão. Valores de dor no peito superiores a 3,5 indicam uma forte associação com a ausência de doença cardíaca (classe Normal), com 109 das 170 amostras iniciais seguindo este ramo. Por outro lado, valores iguais ou inferiores a 3,5 direcionam para um ramo onde predominam casos de doença cardíaca, sugerindo que tipos específicos ou intensidades de dor torácica são indicadores críticos.

ii) Oldpeak:

Para indivíduos com chest_pain ≤ 3.5, o parâmetro oldpeak torna-se crucial. Valores de oldpeak ≤ 0.9 tendem a indicar ausência de doença, enquanto valores superiores a 0,9 estão fortemente associados a doença cardíaca. Esta associação é particularmente evidente no ramo direito da árvore, onde oldpeak > 0.9 leva a classificações consistentes de Heart Disease.

iii) Thalach:

A thalach também demonstra ser um preditor significativo. Valores de thalach ≤ 166.5 estão associados a maior probabilidade de doença cardíaca. Este padrão é consistente com o conhecimento clínico de que pacientes com doença cardíaca frequentemente apresentam menor capacidade de atingir frequências cardíacas elevadas durante exercício físico.

iv) Sex:

O sexo do paciente aparece em múltiplos níveis da árvore, sugerindo que existe uma interação entre o gênero e outros fatores de risco. Em determinados ramos, o sexo masculino ($\text{sex} \leq 0.5$) mostra associação diferenciada com a presença de doença.

A estrutura hierárquica da árvore revela, assim, os seguintes padrões condicionais:

- i) Padrão de Baixo Risco: $\text{chest_pain} \leq 3.5$ AND $\text{oldpeak} \leq 1.25$ -> classificação predominantemente Normal, independentemente de outros fatores, com probabilidade posterior de cerca de 92%.
- ii) Padrão de Alto Risco: $\text{chest_pain} \geq 3.5$ AND $\text{oldpeak} > 0.9$ -> forte associação com Heart Disease, com probabilidade posterior de cerca de 85%.

FIM